

Análisis de métodos de clasificación de series temporales aplicados en mediciones de anomalías con sensores Ford

Jorge Eliecer Galvis Velandia¹, Diego Antonio Yañez Oyarce², Karla Cecilia Puerto López³

Universidad del País Vasco/Euskal Herriko Unibertsitatea^{1,2}, Universidad Francisco de Paula Santander³




Estructura Secundaria de la presentación

- Planteamiento de problema
- Modelos ML evaluados
- Resultados
- Conclusiones



Señales Ford A



K-Nearest Neighbors-DTW

Dado que no es trivial medir la similaridad entre series temporales, se realiza una transformación para calcular este parámetro en otro espacio matemático con la ecuación:

$$c_i = \sum_{j=1}^m \cos \left[\frac{\Pi}{2} \left(j - \frac{1}{2} \right) (i - 1) \right] \quad \forall i = 1 \dots m$$



Time Series Forest

Extensión de Random Forest en series temporales, donde se entrenan múltiples árboles de decisión y se elige el camino que optimice la ganancia de información para ese conjunto de datos.



Métricas de evaluación

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

$$F1 \text{ Score} = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$$



Resultados

TABLE I
PERFORMANCE COMPARISON OF METHODS (*window_size=5 70/30*
TRAIN TEST)

Method	Time (s)	Recall	Precision	Accuracy	F1
DTD_C	51900.95	0.71987	0.72247	0.72257	0.7211
TSF	786.67	0.82273	0.82271	0.8226	0.82273

s = seconds



Conclusiones

- A pesar de obtener métricas similares, TSF es más factible de implementar por el costo computacional de entrenamiento.
- TSF generaliza mejor por su estructura de optimización de árboles de decisión, mientras que kNN depende de conservar la distribución de los datos.



¡Gracias...!

E-mail del expositor

